Hatékony AI folyamok kialakítása

Angyal Sándor[1], Bogdándy Béla[1], Kántor Kristóf[1], and Varga Dorottya[1]
[1]Eötvös Loránd Tudományegyetem Informatikai Kar, Budapest
2026. március 24.

Kivonat

Az utóbbi évek legnagyobb áttöréseket mutató kutatási területe a mesterséges intelligencia. A nagy nyelvi modellek (LLM) [1] térhódításával sokkal hatékonyabbá vált a munkavégzés az élet legtöbb területén. A Multi-Ágens [2] mesterséges intelligencia modellek megjelenésével ez a hatékonyság tovább fokozódik, azonban az, hogy miként célszerű ötvözni ezen modelleket, milyen javasolt és kerülendő praktikák léteznek hatékony folyamok kialakítására, az még nem jól-kiforrott. Ezen kutatás során fokozatosan bonyolodó architechtúrák összehasinlításán keresztül kíséreljük meg feltárni a téma körüli kérdéseket, valamint lehetőség szerint megválaszolni azokat.

Kulcsszavak: AI, AI folyam, AI Ágens, Automatizáció, Optimalizáció

1. Bevezetés

A kutatás bemutatása során az egyes modellek technikai hátterének összehasonlító elemzését végeztük el, különös figyelmet fordítva az alkalmazott architektúrák sajátosságaira. Minden vizsgált megközelítés esetében azonosítottuk és kiemeltük a szakirodalom által javasolt, valamint kerülendő praktikákat. A módszertani szintű összevetés során a javasolt eljárások meghatározásához ezen praktikák metszetét vettük alapul, míg a kerülendő megoldások az egyes tanulmányokban külön-külön megfogalmazott megállapítások szintéziséből kerültek levezetésre.

2. Baseline

Ahogyan a „*More Agents Is All You Need*”[3] cikk mutatja, az Ágensek számának növelésével arányosan skálázódik a modellek performanciája, bármiféle különösebb architechturális tervezés nélkül. A cikkben bemutatott egyszerű kétfázisú mintavétel-és-szavazás alapú model **(Agent Forest)** több ágens eredményeit összevetve hoz döntést a feladat végrehajtása során.

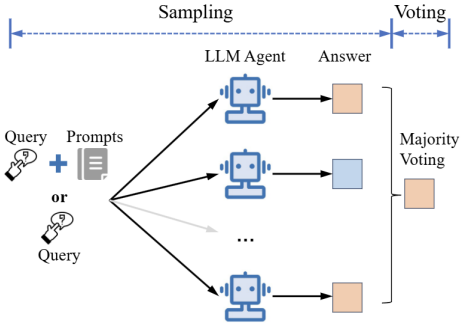

1. ábra. A mintavétel-és-szavazás mechanizmus megvalósítása az Agent Forest modelen belül.[3]

A modellben minden Ágens ugyan azon bemeneti adatokat kapja, amelyre egyénileg adnak választ. Ezen válaszokat kiértékelve, többségi döntés adja a végső kimenetet. A model különböző feladatok során, több LLM-en került kiértékelésre, amely eredménye azt mutatta, hogy az Agent Forest alkalmazása jó praktika a hatékonyság növelésére. A model hátránya, hogy a több Ágens bevezetésével a számítási költség is arányosan nő, amivel ez az egyszerű architektúra tékozlóan bánik. Ezen probléma orvosolására a későbbiekben egyre bonyolodó architechtúrák kerülnek bevezetésre, amelyek okosabb tervzéssel hatékonyabban használják fel rendelkezésre álló erőforrásaikat.

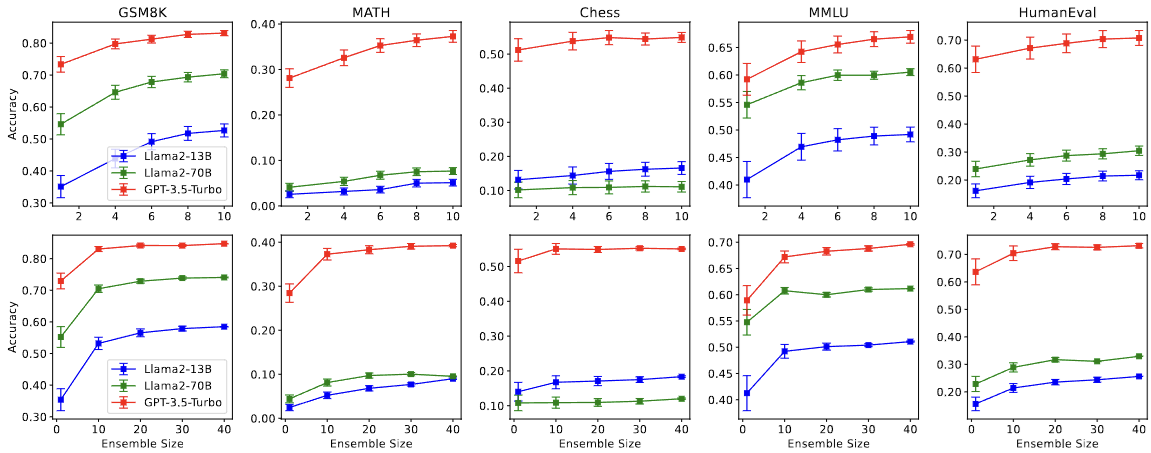

2. ábra. A teszteredmények jól mutatják, hogy az Ágensek számával arányosan nő a performancia.[3]

3. Egyszerű modellek

A Google által készített átfogó kutatási cikk „*Towards a Science of Scaling Agent Systems*" [4] 180 egyedi konfiguráción keresztül, három nagy modellcsaládon (OpenAI, Gemini, Anthropic) és négy komplex benchmarkon (BrowseComp-Plus, Finance-Agent, PlanCraft, Workbench) keresztül. A kísérletekben 5 architechtúra került összevetésre, 1 Single-Agent-System (SAS) és 4 Multi-Agent-System (MAS):

- **SAS:** Egy darab AI Ágens
- **Independent MAS:** Egyszintű model, több egymástól független AI Ágens
- **Decentralized MAS:** Egyszintű model, több egymással kommunikáló AI Ágens
- **Centralized MAS:** Hierarchikus model, 1 Orkesztrátor, több Ágens, az Ágensek csak az Orkesztrátorral kommunikálnak
- **Hybrid MAS:** Hierarchikus model, 1 Orkesztrátor, több Ágens, mindenki mindenkivel kommunikálnak

A teszteket lefuttatva és az eredmények átfogó kiértékelése után az alábbi megfigyelések kerültek ki eredményként a kísérletekből:

- **Az „Eszköz-Koordináció" kompromisszum:** Minél több eszközt kell egy ágensnek használnia, annál rosszabbul teljesít egy többágenses struktúrában. Ennek oka, hogy a koordinációs többletköltség (az ágensek közötti üzenetváltás) felemészti a token-keretet és a kontextus-ablakot, ami elvonja a kapacitást az összetett eszközhasználati logikától.
- **„45% szabály" (Képességszaturáció):** A megfigyelések, hogy ha egy egyedülálló ágens (Single-Agent) már képes elérni a ∼45%-os sikerességi arányt egy feladaton, a további ágensek hozzáadása már nem javít érdemben az eredményen, sőt, gyakran rontja azt. A koordináció akkor hozza a legnagyobb hasznot, ha az alapmodell önmagában gyengén teljesít.
- **Topológia-függő hibaamplifikáció:** A rendszer szerkezete kritikus a hibák terjedése szempontjából:
  - **Független ágensek:** Ha az ágensek nem kommunikálnak, csak párhuzamosan dolgoznak, a hibák **17,2**-szeresen erősödhetnek fel.
  - **Centralizált koordináció:** Egy orkesztrátor jelenlét ezt a hibaerősítést **4,4**-szeresre mérsékli.

Characteristic	SAS	MAS (Independent)	MAS (Decentralized)	MAS (Centralized)	MAS (Hybrid)
Interaction Type	Agent	Agent Agent Agent Aggregation	Agent Agent Agent Majority Voting	Orchestrator Sub-Agent Sub-Agent Sub-Agent	Orchestrator Sub-Agent Sub-Agent Sub-Agent
LLM Calls	$O(k)$	$O(nk) + O(1)$	$O(dnk) + O(1)$	$O(rnk) + O(r)$	$O(rnk) + O(r) + O(p)$
Sequential Depth	k	k	d	r	r
Comm. Overhead	0	1	$d \cdot n$	$r \cdot n$	$r \cdot n + p \cdot m$
Parallelization Factor	1	n	n	n	n
Memory Complexity	$O(k)$	$O(n \cdot k)$	$O(d \cdot n \cdot k)$	$O(r \cdot n \cdot k)$	$O(r \cdot n \cdot k + p \cdot n)$
Coordination	Sequential	Parallel + Synthesis	Sequential Debate	Hierarchical	Hierarchical + Peer
Consensus	-	Synthesis	Debate	Orchestrator	Orchestrator

3. ábra. A különböző modellek összevetése. Az ábrán látható modellek közül az első (SAS) hagyományos megközelítés, egy darab Ágenssel míg a második (Independent MAS) analóg a korábbiakban bemutatott Agent Forest modellel. A további modellek a különböző hierarchikus megközelítéseket jelöli[4]

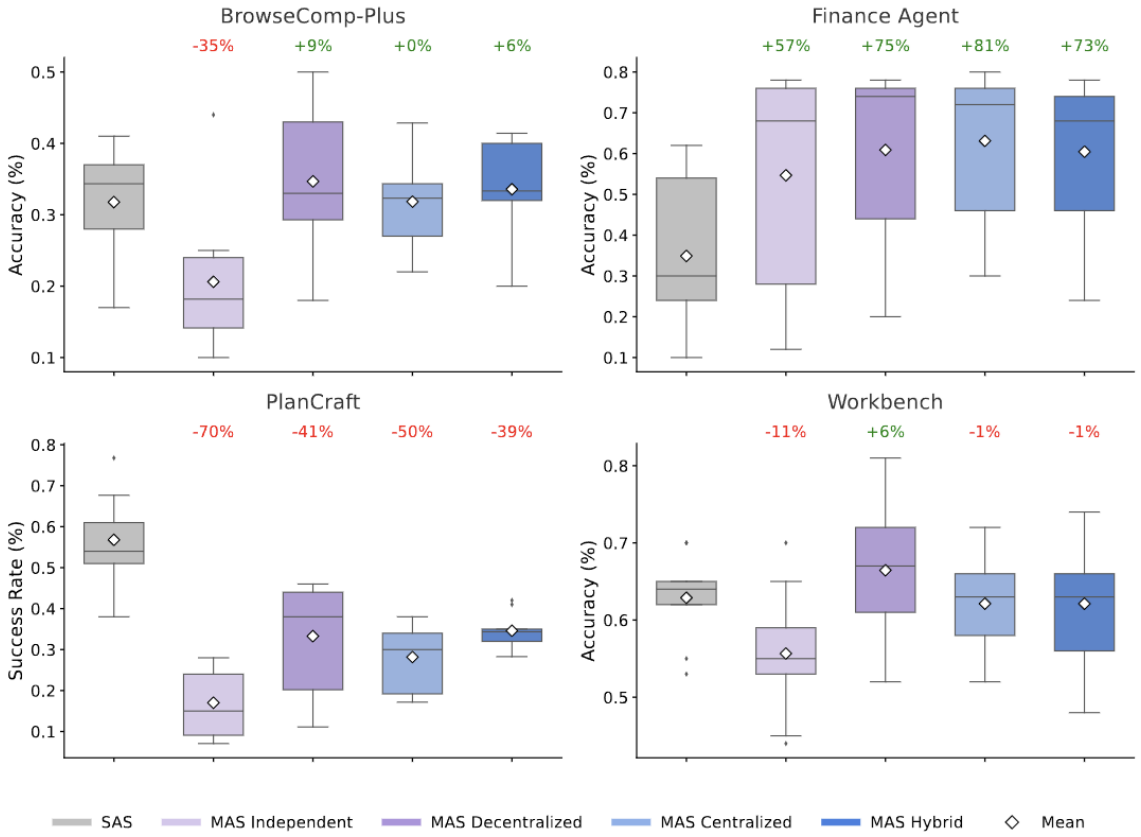

4. ábra. A Különböző benchmarkok eredményei. Az eredményeken látszik a korábbiakban felsorolt megfigyelési eredmények, melyek jól mutatják, hogy a Multi-Ágens megközelítés nem minden esetben hoz javulás. A javulás jellemzően a jól paralellizálható, komplex feladatok megoldásakor volt kiemelkedő. [4]

A bemutatott modellek eredményeiből jól látszik, mikor okoz a több ágens használata szignifikáns javulást, mikor pedig drasztikus teljesítményromlást. Vegyük észre azonban, hogy az imént bemutatott modellek mind merev megkötéseket alkalmaztak, folyam jellegű keretrendszereket mellőzve...

4. AI Folyamok

Jogosan merül fel, az igény a szekvenciális végrehajtásra, ahol az egyik Ágens kimenetét kapja egy másik Ágens bemenetként és ezen információkat felhasználva hoz döntést a probléma megoldására. Ezt a megközelítési módot AI folyamnak nevezik. Létrehozásukra számos keretrendsszer létezik, amelyek közül néhány ezen fejezetben kerül összehasonlításra egymással, meghatározva hogy milyen tervezési mintákat szem előtt tartása nyújt segítséget hatékony AI folyamok kialakításakor.

4.1. Free-MAD

A „*Free-MAD:Consensus-Free Multi-Agent Debate*" [5] tanulmány rávilágít arra, hogy az LLM-ek kollektív döntéshozatala gyakran örökli az emberi szociálpszichológiából ismert kognitív torzításokat. Ezek az alábbiak:

A kényszerített konszenzus és a konformitási torzítás a hagyományos többágenses vitarendszerek(MAD) jellemzően arra utasítják az ágenseket, hogy cseréljenek eszmét, kritizálják egymás megoldásait, és több iterációs körön keresztül jussanak el egy közös, végső megegyezésig. Bár ez a megközelítés intuitívnak tűnik, a modellek működési sajátosságai miatt súlyos anomáliákhoz vezethet. A Free-MAD kutatás bebizonyította, hogy az LLM ágensek rendkívül hajlamosak a konformitásra, amikor a vitafolyamat során egy ágens azzal szembesül, hogy a többi egyöntetűen más álláspontot képvisel, a modell valószínűségi eloszlása eltolódik az alkalmazkodás irányába, a naiv szavazás vagy a kényszerített megegyezés nem a legmagasabb minőségű választ, hanem a legkorábban kialakult többségi narratívát emeli ki győztesként.

Free-MAD paradigma

A konformitási torzítás kiküszöbölésére a Free-MAD keretrendszer egy radikális architekturális váltást javasol: a generatív vitafázis és a döntéshozatali aggregációs fázis teljes szétválasztását (5. ábra). A "Consensus-Free" megközelítés lényege, hogy a rendszer promptolási és orchestrációs szintjén kifejezetten megtiltják az ágenseknek, hogy megegyezésre törekedjenek. Az ágensek feladata kizárólag saját logikai útjuk felépítése, a többiek érveinek kritikai elemzése, és a saját álláspontjuk bizonyítékokkal történő alátámasztása.

Ez a módszertani változtatás a következő előnyökkel jár az automatizáció során:

- **A divergens gondolkodás megőrzése:** Az ágensek nem kényszerülnek kompromisszumos megoldások generálására, így a teljes logikai tér feltérképezésre kerül.
- **A visszakozás eliminálása:** A helyes választ adó kisebbség nem vonja vissza az érveit a többségi nyomás hatására.
- **Párhuzamosítási lehetőségek:** Mivel nincs szükség arra, hogy a modellek minden kör végén megvárják a globális konszenzust, a rendszer számítási szempontból is hatékonyabbá válik.

Ha a rendszer nem kényszeríti a konszenzust, és elveti a szavazatszámlálást, akkor a kérdés:

Hogyan dől el a végeredmény?

A Free-MAD architektúra innovációja a **pontozásos aggregációs mechanizmus**. A rendszer szabályrendszert alkalmaz a különböző ágens-kimenetek kiértékelésére. A döntést egy független ágens hajtja végre, amely az alábbiak mentén pontozza a levezetéseket:

- **Tényszerű megalapozottság:** Milyen mértékben támaszkodik az ágens a bemeneti adatokra, vs. külső infromációkra.
- **Logikai koherencia:** Vannak-e ellentmondások az ágens saját levezetésének lépései között?
- **Kritika ellenállás:** Hogyan reagált az ágens a többi modell által felhozott ellenérvekre? Sikerült-e azokat cáfolnia?

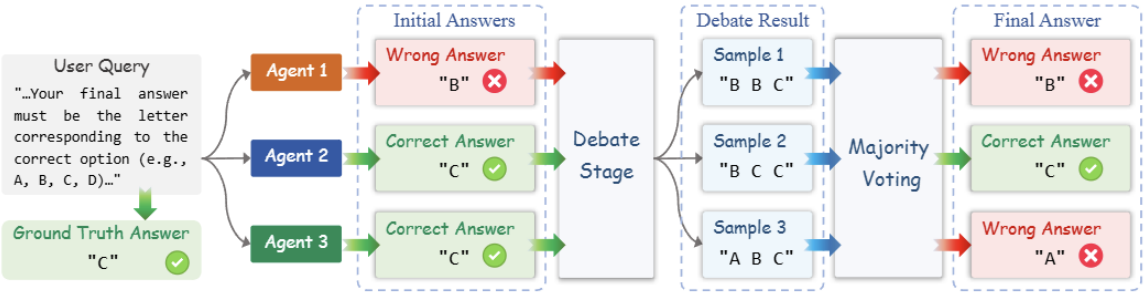

5. ábra. A Free-MAD architektúra belső működése. Az architektúra belsejében a különböző Ágensek folyamokban vannak rendezve. A Folyam bemenete egy query, amelyet az egyes ágensek külön-külön kapnak meg, döntéseiket egyénileg hozzák meg. Ezt követően az Ágensek eredményei keresztül mennek a pontozásalapú aggregációs mechanizmuson amely eredményeként a folyam kimenetén megjelenik a végső válasz.[5]

A végső döntés tehát nem egy fekete dobozos szavazás eredménye, hanem egy súlyozott, kvantitatív pontozásos modell kimenete. A győztes válasz az az ágens-kimenet lesz, amely a szabályrendszer alapján a legmagasabb aggregált pontszámot éri el, függetlenül attól, hogy a generálási fázisban a többség vagy a kisebbség képviselte-e azt.

Az architektúra ismeretében az alábbi kerülendő és javasolt tervezési praktikák fogalmazhatóak meg:

Kerülendő praktikák:

- **A vak többségi szavazás alkalmazása**
  Bár az egyszerű szavazás kiválóan működik determinisztikus vagy egyszerű kódolási feladatoknál, a többváltozós, komplex érvelést igénylő folyamatoknál naívan a többségre hagyatkozni gyakran konfabulációs konszenzusba csap át.
- **A megegyezés kikényszerítése**
  Nem szabad az ágensek célfüggvényébe beépíteni a közös álláspont elérésének kényszerét, mert ez minőségromlást és a helyes látásmódok elvesztését eredményezi.

Javasolt praktikák:

- **Generálás/döntéshozatal szeparálás**
  A folyamot érdemes úgy strukturálni, hogy a vitázó/ötletelő ágensek hálózata ne legyen felelős a végső döntésért.
- **Pontozásos szabályok bevezetése**
  A folyam végpontján egy egyértelmű metrikákra épülő (determinisztikus, kódszintű/egy független meta-ágens által vezérelt) auditáló vagy pontozó réteget kell alkalmazni, amely objektív szabályok alapján választja ki a legjobb megoldást.
- **Aszinkron véleményalkotás**
  Az első iterációban az ágenseknek anélkül kell legenerálniuk a válaszaikat, hogy látnák a többi választ. Így elkerülhető a korai megalapozottsági torzítás, és biztosítható, hogy a vitába kerülő érvek független forrásból származnak.

Összegzés: A Free-MAD architektúra jó példa arra, hogy a multi-ágens rendszerek hatékonysága nem csak a hálózatba kapcsolt modellek számától függ. A hatékonyságnövekedés kulcsa a szociális torzítások kiszűrése, a divergens gondolkodás algoritmikus védelme, valamint az egyszerű szavazást felváltó, szabályalapú aggregációs mechanizmusok alkalmazása a folyamokban.

4.2. Cognify

Az AI folyamok egyik kulcsproblémája nem pusztán a megfelelő architektúra kiválasztása, hanem annak hatékony hangolása is. A legtöbb generatív AI folyamat esetében a különböző komponensek, azaz a modellek, promptok, illetve egyéb köztes feldolgozási lépések beállítása általában a fejlesztő intuíciói alapján, manuálisan történik. A fejlesztők tipikusan próbálgatásos módszerrel változtatják a modellválasztást, a promptok szerkezetét vagy a lépések sorrendjét, miközben figyelik a válaszminőség, a késleltetés és a költség alakulását. Ez a megközelítés azonban rosszul skálázódik, hiszen a folyamat akár több modellhívást vagy eszközhasználatot tartalmaz.

A *Cognify: Supercharging Gen-AI Workflows With Hierarchical Autotuning* [6] című cikkben taglalt megközelítés ezt a problémát az AI folyamok automatizált optimalizálásával kezeli.

Ahogy azt a 6. ábrán is láthatjuk, a rendszer a teljes feldolgozási láncot irányított gráfként modellezi:

- a csomópontok egy-egy számítási lépést reprezentálnak, például egy nagy nyelvi modell hívását, egy külső API használatát vagy egy eszköz által végrehajtott feldolgozást,
- az élek pedig az egyes lépések közötti adatáramlási kapcsolatot jelölik.

Ez a reprezentáció lehetővé teszi, hogy a teljes folyamat egy strukturált optimalizálási térként legyen kezelhető.

A Cognify az optimalizálási lehetőségeket három fő szintre bontja, melyek céja együttesen az optimális konfiguráció megtalálása.

1. Az architektúra szintje, amely a workflow szerkezetének módosítását jelenti, például új lépések hozzáadását vagy meglévő lépések eltávolítását.
2. Az egyes lépések konkrét implementációjának kiválasztása, például annak meghatározása, hogy egy adott részfeladatot melyik modell vagy eszköz oldjon meg.
3. A finomhangolási paraméterek módosítása, ide tartoznak például a promptok variációi vagy a generálási beállítások.

A rendszer működésének központi eleme az AdaSeek nevű hierarchikus keresőalgoritmus. Az AdaSeek nem egyetlen, lapos konfigurációs térben keres optimális megoldást, hanem rétegezett módon vizsgálja a lehetséges konfigurációkat. A keresés első lépésben a magasabb szintű architekturális alternatívák között történik, majd az ígéretes struktúrákon belül alacsonyabb szinten kerülnek vizsgálatra az egyes lépések és paraméterek variációi. A rendelkezésre álló értékelési költségkeretet adaptívan osztja el a különböző szintek között, így azok a részek kapnak nagyobb figyelmet, ahol nagyobb teljesítményjavulás várható. A keresés során Bayes-alapú mintavételezés segíti az új konfigurációk kiválasztását, amely a korábbi kiértékelések eredményeit felhasználva irányítja a további vizsgálatokat.

Ez a hierarchikus autotuning különösen fontos a hatékony AI folyamok kialakításában. A rendszer képes egyszerre figyelembe venni több optimalizációs célt, például a válaszminőség javítását, a késleltetés csökkentését és a számítási költség minimalizálását. Ennek eredményeként a munkamenet különböző konfigurációi közül a felhasználó számára megfelelő megoldások választhatók ki, amelyek különböző kompromisszumokat kínálnak a teljesítmény és az erőforrásfelhasználás között.

A Cognify megközelítése megmutatja, hogy az AI folyamok hatékonysága nem feltétlen az alkalmazott modellek minőségétől vagy az ágensek számától függ, hanem a teljes, átfogó rendszer optimalizáltságától is. Az eféle automatizált workflow-hangolás lehetővé teszi, hogy a komplex AI modellek jobban kihasználják a rendelkezésre álló erőforrásokat, miközben stabilabb és hatékonyabb működést biztosítanak.

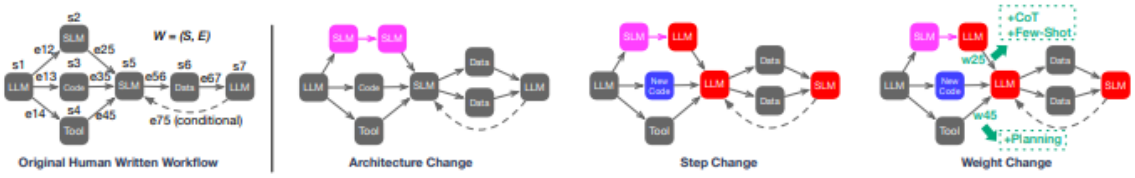

6. ábra. Példa egy Generatív AI munkamenet finomhangolására[6]

4.3. AgentOrchestra

A több ágensbő álló modellek legnagyobb kivhívása a megfelelő koordinációs mechanizmus létrehozása. Ennek orvoslására hozták létre az AgentOrchestra-t, ami egy hierarchikus multi-ágens architektúra.

A „*AgentOrchestra: A Hierarchical Multi-Agent Framework for General-Purpose Task Solving*" [7] alapján az AgentOrchestra alapötlete egy zenekar mintája volt. Miként egy zenekarban a karmester vezényli a különböző hangszereket, úgy az AgentOrchestra rendszerben egy központi tervező ágens koordinálja a többi specializált alágenst. A tervező ágens elemzi a problémát, részfeladatokra bontja és delegálja a megfelelő alágenseknek, így hatékonyan tudja kezelni a komplex problémákat, és lehetőséget ad a dinamikus tervfrissítésekre és a valós idejű alkalmazkodásra. A rendszer támogatja az ágensek közötti kommunikációt és az adaptív szerepkiosztást, ez különösen fontos olyan feladatok esetén, amelyek több lépést, különböző eszközök használatát, vagy többféle információforrás integrálását igénylik.

Az AgentOrchestra rendszerben többféle specializált ágens működik. Ezek az ágensek különböző eszközöket és technikákat alkalmazhatnak, például adatfeldolgozási algoritmusokat vagy webes lekérdezéseket. A rendszer képes multimodális információk feldolgozására is, vagyis nemcsak szöveges, hanem más típusú adatokat – például képeket vagy dokumentumokat – is képes kezelni.

- **Mélykutató ágens**
  A mélykutató ágendt információ gyűjtésre szánták, kifinomult kutatási módszertannal. Két legfontosabb eszköze a Deep Researser Tool a webes információ kereséshez, és egy Python Interpreter Tool az adatfeldolgozáshoz. Ez elöbbi lekérdezés alapú paradigmákon keresztül végez célzott kereséseket, míg utóbbi lehetőséget teremt a heterogén adatfeldolgozásnak és elemzésnek.

- **Böngészőhasználati ágens**
  Ezt az ágenst a pontos, célzott információgyűjtésre tervezték. Feladatai közé a keresés, a navigáció, a tartalom kinyerés és a dokumentumkezelés tartozik. Így támogatva az ágensek számára összetett munkafolyamatok végrehajtását, mint például a dinamikus űrlapkitöltést, a PDF- és videóvezérlést, valamint a fülek kezelését.

- **Mélyanalizáló ágens**
  Amélyanalizáló ágens az adat elemzési és -értelmezési feladatokhoz készült, mely a felhasználótól kapott forrásanyagokon és analítikai feladatokon dolgozik. A Python Interpreter Tool lehetővé teszi saját analitikai szkriptek végrehajtását, segítve az ágens képességét az összetett, multimodális adatforrások feldolgozására. Minden feladathoz akár több nagy nyelvi modellt is meghív a lépésenkénti következtetés végrehajtásához, opcionálisan több modell eredményeit veti össze a pontosság és a robusztusság biztosítása érdekében.

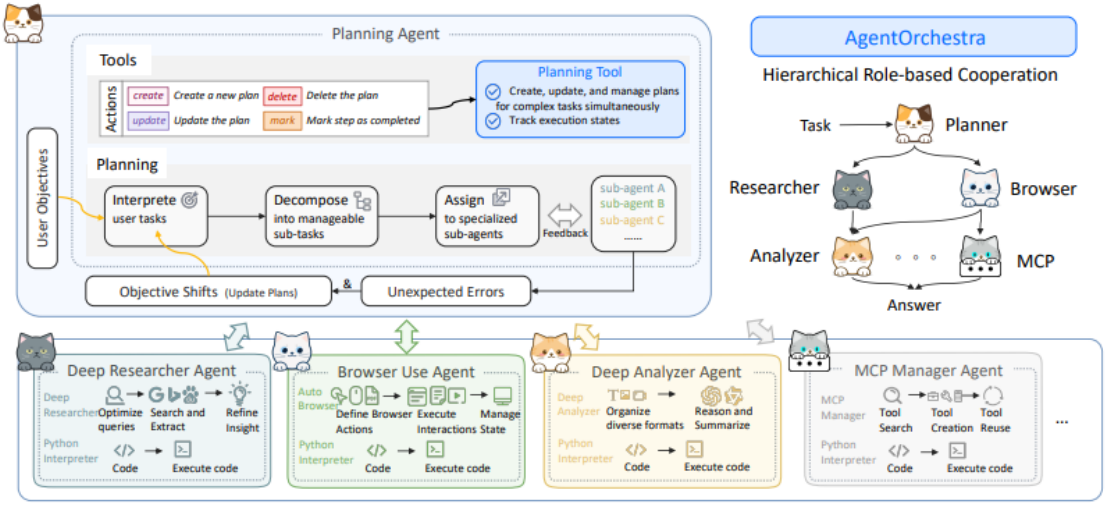

7. ábra. Az AgentOrchestra architechtúrája. [7]

Kerülendő praktikák:

- **Monolítikus ágensek**
  Mindenképpen kerülendő a monolitikus ágensek használata, azaz amikor egy nagy modellel próbálunk minden feladatot megoldani. A legtöbbször sok kontextust igényel, növeli a költségeket és bonyodik a hibakeresés.
- **"Lapos" multi ágensek**
  Szintén problémát okozhat ha minden ágens egyenrangúként kezeli a többit és eszerint kommunikál velük. Ez könnyen vezethet redundáns munkához és káoszos kommunikációhoz.
- **Túl sok ágensek**
  A túl sok ágens használata túlterheli a kommunikációs csatornákat, ezáltal lassítja a munkafolyamatokat.

Javasolt praktikák:

- **Hierarchikus felépítés** A központi koordináló ágens és az al ágensek hierarchikus felépítése segíti az egyes rész feladatok hatékony végrehajtását, csökkenti a hibák előfordulását és átláthatóbbá teszi a rendszer működését.
- **Moduláris architectúra** A rendszer komponensekre bontása lehetővé teszi a könyű bővíthetőséget és módosítást.
- **Multimodális működés**
  Mivel a szöveges források mellett képekkel, webes adatokkal és fájlokkal is dolgoznia kell a rendszernek, célszerű úgy megtervezni a workflowkat hogy több féle forrást tudjon integrálni.

5. Módszertan

A kutatás során három kiemelt Multi-Ágens és generatív AI workflow-t vizsgáltunk: a Free-MAD, a Cognify és az AgentOrchestra rendszereket. A vizsgálat módszertanát esettanulmányos és kísérleti jellegű megközelítésre építettük, amely lehetővé teszi a különböző architektúrák valós és szimulált környezetben történő összehasonlítását. Első lépésként az egyes workflow-k felépítését és működési elvét részletesen feltérképeztük, az ágensek számát, a hierarchiát, az adatáramlás módját és a döntéshozatali mechanizmusokat dokumentáltuk. Ezután a rendszereket azonos típusú feladatokon teszteltük, amelyek komplexitásukban és párhuzamosíthatóságukban tükrözték a valós alkalmazási környezeteket, beleértve matematikai-logikai problémamegoldást, szöveges generálást, multimodális információfeldolgozást és webes lekérdezéseket.

A kísérletek során kvantitatív és kvalitatív mérőszámokat alkalmaztunk a teljesítmény, pontosság, erőforrás-felhasználás és hibaarány értékelésére. A kvantitatív elemzés keretében minden workflow-t többször futtattunk, rögzítve a token-felhasználást, a CPU/GPU időt és a válaszidőt, míg a kvalitatív elemzés során a döntési folyamatokat és a hibák forrásait vizsgáltuk, különös tekintettel a kerülendő gyakorlatokra, mint a monolitikus ágensek alkalmazása vagy a konszenzuskényszer. Az összehasonlítás lehetővé tette, hogy azonosítsuk az egyes workflow-k erősségeit és gyengeségeit: a Free-MAD a divergens gondolkodás és a konformitási torzítás minimalizálásában mutatott kiemelkedő teljesítményt, a Cognify a teljes workflow automatizált optimalizálásában és a költséghatékony működés biztosításában volt erős, míg az AgentOrchestra a hierarchikus koordináció és a multimodális adatfeldolgozás terén bizonyult a leghatékonyabbnak.

6. Eredmények

A vizsgálat során kapott eredmények szoros összhangban álltak az irodalomkutatás során ismertetett tapasztalatokkal: megerősítést nyert, hogy a több ágensek száma önmagában nem garantál teljesítménynövekedést, a hierarchikus felépítés és a moduláris architektúra a hatékonyság kulcsa, valamint az automatizált workflow-optimalizálás jelentősen javítja a stabilitást és az erőforrás-hatékonyságot. Emellett a kerülendő gyakorlatok – például a vak többségi szavazás, a monolitikus ágensek vagy a túlzott konszenzus-kényszer – ténylegesen rontották a rendszer pontosságát és teljesítményét, ami megerősítette az irodalomban szereplő javaslatokat a jól megtervezett, szabályalapú és hierarchikus Multi-Ágens architektúrák előnyéről.

7. Összefoglalás

A dolgozat során áttekintettük a Multi-Ágens és generatív AI workflow-k fejlődését, különös tekintettel a Free-MAD, a Cognify és az AgentOrchestra rendszerekre. Bár a technológia gyorsan fejlődik, a hatékony AI folyamok kialakításához még mindig nélkülözhetetlen a tudatos architektúra-tervezés, a moduláris felépítés és a szociális torzítások minimalizálása. A vizsgálat rávilágított, hogy a workflow-k optimalizálása nem csupán az ágensek számától vagy a modellek képességeitől függ, hanem a koordinációs mechanizmusok, a döntéshozatali stratégiák és az erőforrások kezelése kulcsfontosságú tényezők.

Összességében a dolgozat bemutatja, hogy a Multi-Ágens AI folyamok fejlesztése nem pusztán technológiai kihívás, hanem tervezési és optimalizációs folyamat, ahol a gondos architektúra-tervezés, az algoritmikus szabályok és a rendszeres finomhangolás együttesen biztosítják a hatékony és megbízható működést.

Hivatkozások

[1] Wayne Xin Zhao, Kun Zhou, Junyi Li, Tianyi Tang, Xiaolei Wang, Yupeng Hou, Yingqian Min, Beichen Zhang, Junjie Zhang, Zican Dong, et al. A survey of large language models. *arXiv preprint arXiv:2303.18223*, 1 (2):1–124, 2023.

[2] Ranjan Sapkota, Konstantinos I Roumeliotis, and Manoj Karkee. Ai agents vs. agentic ai: A conceptual taxonomy, applications and challenges. *Information Fusion*, page 103599, 2025.

[3] Junyou Li, Qin Zhang, Yangbin Yu, Qiang Fu, and Deheng Ye. More agents is all you need. *arXiv preprint arXiv:2402.05120*, 2024.

[4] Yubin Kim, Ken Gu, Chanwoo Park, Chunjong Park, Samuel Schmidgall, A Ali Heydari, Yao Yan, Zhihan Zhang, Yuchen Zhuang, Mark Malhotra, et al. Towards a science of scaling agent systems. *arXiv preprint arXiv:2512.08296*, 2025.

[5] Yu Cui, Hang Fu, Haibin Zhang, Licheng Wang, and Cong Zuo. Free-mad: Consensus-free multi-agent debate. *arXiv preprint arXiv:2509.11035*, 2025.

[6] Vikranth Srivatsa Yiying Zhang Zijian He, Reyna Abhyankar. Cognify: Supercharging gen-ai workflows with hierarchical autotuning. *https://arxiv.org/abs/2502.08056*, 2025.

[7] Yuzhen Xiao Yongcong Li Ce Cui Yilei Zhao Rui Hu Yang Liu Yahui Zhou Bo An Wentao Zhang, Liang Zeng. Agentorchestra: A hierarchical multi-agent framework for general-purpose task solving. *https://arxiv.org/pdf/2506.12508v3*, 2025.